


# Sorodna dela

Neza Krzan

Ocenjevanje resnosti Parkinsonove bolezni trenutno temelji na nevroloških pregledih v abulanti, kjer pacient izvaja motorične naloge, ki so opisane v lestvici *Movement Disorder Society-Unified Parkinson's Disease Rating Scale* (MDS-UPDRS). Ker so pregledi in ocene subjektivni, je raziskovanje objektivnega ocenjevanja pogosto raziskovana tema z različnimi rešitvami.

## 1 Preučevane naloge v dosedanjih študijah

Različna dela proučujejo različne znake Parkinsonove bolezni, vendar med najpogostejše preučevanimi je tapkanje s prsti (*finger tapping*), sledi ji gibanje rok (*hand movements*), pronacija-supinacija (*pronation-supination*) in tremor. Pogosto so tapkanje s prsti, gibanje rok in pronacija-supinacija preučevane skupaj, ker naj bi bile celoten pokazatelj ocene MDS-UPDRS([14]).



Slika 1: Deleži preučevanih znakov Parkinsonove bolezni v pregledanih delih.

Študije sledijo kliničnim ciljem - stadij bolezni (ocena po MDS-UPDRS), prepoznavanje bolezni v primerjavi z zdravimi kontrolnimi primeri in ocena specifičnih simptomov (oceno tremorja, bradikinezije); največ študij se ukvarja z oceno bolezni po MDS-UPDRS in primerjavo značilnosti z zdravo kontrolno skupino([7]). Pri ocenjevanju stadija bolezni po MDS-UPDRS gre za kompleksen problem, zlasti med sosednjimi ocenami. Študije poročajo o nizki povprečni natančnosti (*across-task* in *across-cross-validation-stage accuracy*), vendar o dobri vrednosti sprejemljive natančnosti (*acceptable accuracy*). Pri prepoznavanju bolezni oz. diagnozi bolezni pa poročajo o visokih natančnostih, zlasti pri tapkanju s prsti.

Ocenjevanje telesnih gibov (*HPE – Human Pose Estimation*) celotnega telesa je doseglo izjemno natančnost, sledenje gibom rok pa zaenkrat še predstavlja izzive. Podobno kot pri ocenjevanju telesnih gibov, tudi pri sledenju rok uporabljajo različne pristope - uporaba nosljivih naprav (IMU, senzorske rokavice) in uporaba računalniškega vida([2]).

## 2 Pridobivanje videoposnetkov oz. podatkov

Objektivno ocenjevanje uporablja nosljive in nenosljive tehnologije za ocenjevanje merjenih značilnosti gibanja. Obstajajo tudi mešani pristopi, pri katerih se uporablja kombinacija računalniških vida in pasivnih ali aktivnih nosljivih naprav([8]). Podatki, zbrani na ta način, se nato analizirajo z modeli, ki ocenjujejo motorične

sposobnosti pacienta. Nosljive naprave predstavljajo uveljavljen pristop za objektivno ocenjevanje stopnje Parkinsonove bolezni in pogosto presegajo tradicionalne pristope računalniškega vida. Večina nosljivih naprav temelji na IMU, ki zaznavajo gibe rok ali na MG senzorjih za merjenje mišične aktivnosti. Tapkanje s prsti (*finger tapping*) ter proučevanje gibov rok pa bolj temelji na analizi video posnetkov in globokem učenju. Ker je ta način je zelo raziskovana metoda v zadnjih letih, smo se tudi mi osredotočili na pregled del, ki temeljijo na tem pristopu.

Različne študije so se poslužile zajema podatkov na različne načine (npr. tipkanje na tipkovnico, uporaba nosljive naprave nameščene na kazalcu), med najbolj priljubljenimi načini pa so videoposnetki tapkanja s prsti.

Posnetki so bili pridobljeni v ustreznem okolju (ambulanta ali laboratorij) z uporabo standardnih kamer ali kamer telefonov (15fps, 30fps ali 60fps, večin 1920x1080 slikovnih pik ali 3840x2160 slikovnih pik), ponavadi nameščenih na stojalo, ki je bilo v večini študij 1m oddaljen od roke oz. palca in kazalca.


Pri osebah s Parkinsonovo boleznijo so v večini študij prevladovali moški in bolniki z diagnozo, ki je bila postavljena s strani specialista pred manj kot dvema/tremi/petimi leti (v večini študij) s strani nevrologa. Nekateri študije so obravnavale osebe s Parkinsonovo boleznijo, ki se ne poslužujejo nobeni terapiji, pri nekaterih študijah pa to ni bilo pomembno. Osebe s Parkinsonovo boleznijo so naloge običajno izvajale z obema rokama, pri čemer so se posnetki leve in desne roke obravnavali kot neodvisni, saj je lahko ocena leve in desne strani različna po MDS-UPDRS. Naloga se je izvajala le enkrat, saj pri osebah s Parkinsonovo boleznijo ponovno izvajanje naloge ne prinese realne predstavitve stanja bolezni, zaradi utrujenosti. V nekaterih študijah pa so bili vključeni tudi posnetki zdravih oseb, t.i. kontrolnih oseb, ki niso imeli zgodovine Parkinsonove bolezni ali druge nevrološke bolezni, zaradi specifičnosti obravnavanega problema. Zdrave osebe pa so naloge izvajale le z dominantno roko.

Osebam je bilo ponavadi pokazano kako naj izvajajo nalogo, med samim izvajanjem pa jih niso popravljali. Nalogo tapkanja s prsti so v večini izvajali po 10 ali 15 sekund.

### 3 Obdelava video posnetkov in podatkov

Algoritmi oziroma arhitekture, ki so jih izdelali v študijah vsebujejo različne načine obdelovanja posnetkov. V posnetkih sledijo gibanju rok oz. oceni pozicije roke s pomočjo različnih orodij, obstajajo pa tudi primeri ko so uporabili globoko nevronske mreže neposredno na videoposnetkih tapkanja s prsti.


Sledenje gibom rok na podlagi videoposnetkov oz. ocena pozicije rok (*hand pose estimation*) je metoda pridobivanja nabora položajev sklepov rok iz *RGB*, *depth* in *RGB-Depth* video posnetkov. Za detekcijo roke večina uporablja nabor sklepov z različnimi orodji. Večina uporablja nabor sklepov, ki se uporablja v orodjih *OpenPose* in *MediaPipe*, je model roke COCO (*COCO Hand model*), sestavljen iz 21 točk, ki predstavljajo glavne sklepe roke, kot je prikazano na spodnji sliki (slika vzeta iz [10]).



Slika 2: COCO Hand model, tipična konfiguracija sklepov v orodjih *OpenPose* in *MediaPipe*.

Torej zaznavanje drže roke oziroma položaj sklepov je večina študij pridobila s pomočjo orodij *MediaPipe*, *OpenPose*, *DeepLabCut* in *MMPose*, ki so v zadnjih letih najbolj uporabna. Za roko vrnejo skelet 21 točk iz

katerih so potem računali različne značilke.



Slika 3: Deleži uporabljenih orodij v preučevanih delih za sledenje rok in zaznavanje drže roke iz videoposnetkov.

Dogajalo se je tudi, da zgornja orodja niso zaznala vseh sličic videoposnetka in so podatki imeli mankajoče točke skeleta posameznih sličic. Nekateri so se problema lotili z linearno interpolacijo, ki so jo uporabili le v primeru, ko je orodje zaznalo prejšnjo in naslednjo sličico. Posnetke, kjer orodja niso zaznala več sličic, so odstranili iz podatkov.

Identificirali so tudi posamična gibanja tapkanja s prsti - cikel tapkanja. Nekateri so se problema lotili z izračunom razdalje med palcem in kazalcem oz. kotne razdalje med palcem in kazalcem in na podlagi tega ter standardnih algoritmov določili vrh in dno amplitude oz. odpiranje in zapiranje prstov. Večina se jih je posluževalo izračuna evklidske razdalje med palcem in kazalcem, saj so bili kot občutljivi na nagib kamere - med kamero in roko bi moralo biti 90 stopinj.

Orodja so v podatke vpeljala visokofrekvenčne šume, ki nastanejo zaradi prileganja skeleta orodja roki in tremorja oseb s Parkinsonovo boleznijo. Pridobljene razdalje oz. kote so zato zgladili na različne načine.

Nekatere študije so se lotile tudi problema neravnovesja razredov - večina je bila uporabljen tehnika SMOTE(*Synthetic Minority Oversampling Technique*). S to tehniko so povečali manj zastopane razrede in zmanjšali prekomerno zastopane razrede v njihovih podatkih.

Pred računanjem značilk so nekateri avtorji, predvsem tisti, ki se niso posluževali ročnega računanja značilk, podatke normalizirali z uporabo povprečja in standardne deviacije podatkov(Z-score normalization).

## 4 Značilke

Večina avtorjev je svoje modele gradila na ročno izračunanih značilkah(*manual features*) glede na smernice ocen po lestvici MDS-UPDRS. Ker pa nekateri niso dobro poznali problema in značilnosti Parkinsonove bolezni, ali pa so model, naučen na ročno izračunanih značilkah, želeli primerjati, so se izračuna značilk lotili z nevronskimi mrežami. Kot vhodni podatek so podali časovno zaporedje podatkov, model pa je iz njih izločil značilke.

Ročno računanje značilk je temeljilo na signalih, ki so predstavljali pospešek(*acceleration*), kotna hitrost(*angular velocity*), premik(*displacement*) in kot(*angle*) v časovni vrsti.

Za izračun sprememb območja in hitrost tapkanja prstov so avtorji po večini izbrali dvodimenzionalne podatke o sklepih, kjer je posamezen sklep  $J_i$ ,  $i = 1, \dots, 21$ (model roke COCO) definiran kot  $J_i = (x_i, y_i)$  oz. trodimenzionalne podatke o sklepih, torej posamezen sklep  $J_i$ ,  $i = 1, \dots, 21$ (model roke COCO) je definiran kot  $J_i = (x_i, y_i, z_i)$ , s katerimi so računali evklidske razdalje med posameznimi sklepi v določenem časovnem okvirju, najpogosteje razdaljo med palcem in kazalcem([10]). Evklidska razdalja med palcem in kazalcem v časovnem okvirju  $t$  za dvodimenzionalne podatke je definirana kot

$$D_t = d(J_4^t, J_8^t) = \sqrt{(x_4^t - x_8^t)^2 + (y_4^t - y_8^t)^2}$$

oz. za trodimenzionalne podatke

$$D_t = d(J_4^t, J_8^t) = \sqrt{(x_4^t - x_8^t)^2 + (y_4^t - y_8^t)^2 + (z_4^t - z_8^t)^2}.$$

Med najpogostejše izbranimi značilkami so bile amplituda, hitrost, utrujenost oz. zastoj in oklevanje ter frekvenca. Te značilke so bile definirane in izračunane na različne načine, glede na študijo.

#### 4.1 Amplituda(*amplitude*) in hitrost(*velocity*)

Amplituda in hitrost sta dve najbolj običajni značilki, ki se analizirata za oceno Parkinsonove bolezni z uporabo tapkanja s prsti. V večini primerov sta definirani kot:

*Amplituda: razdalja med palcem in kazalcem.*

*Hitrost: razlika v amplitudi skozi čas.*

**Definicija:** V podatkih, pridobljenih s pomočjo orodja, lahko definiramo vrhove amplitude kot  $p = [p_1, p_2, \dots, p_N]$ , kjer  $p_n$  predstavlja vrh  $n$ -te amplitude in  $A_n$  predstavlja pripadajočo amplitudo vrha  $p_n$ . Definirajmo še minimume amplitud kot  $m = [m_1, m_2, \dots, m_N]$ . Potem lahko definiramo naslednje pojme ([13], [9]).

*Amplituda odpiranja* je razlika med najvišjo in najnižjo točko v fazi odpiranja gibanja. Izračuna se po formuli  $F_{amp-opn} = p_n - m_n$ .

*Amplituda zapiranja* je razlika med najvišjo in najnižjo točko v fazi zapiranja gibanja. Izračuna se po formuli  $F_{amp-cls} = p_{n-1} - m_n$ .

*Hitrost odpiranja* je razlika med največjim in najmanjšim vrhom v fazi odpiranja gibanja, deljena z ustreznim časovnim intervalom. Izračuna se po formuli

$$F_{spd-opn} = \frac{p_n - m_n}{tp_n - tm_n}.$$

*Hitrost zapiranja* je razlika med največjim in najmanjšim vrhom v fazi zapiranja gibanja, deljena z ustreznim časovnim intervalom. Izračuna se po formuli

$$F_{spd-cls} = \frac{p_{n-1} - m_n}{tp_{n-1} - tm_n}.$$

*Povprečje amplitude* je

$$F_{amp-mean} = \frac{\sum_{n=1}^N A_n}{N}.$$

*Varianca amplitude* je

$$F_{amp-var} = \frac{\sum_{n=1}^N (A_n - F_{amp-mean})^2}{N}.$$

*Povprečna hitrost gibanja prsta* je


$$F_{spd-mean} = \frac{\sum_{n=1}^{N-1} V_n}{N-1},$$

kjer je  $V_n = \frac{A_n + A_{n-1}}{\Delta t_n}$ ,  $\Delta t_n = t_n - t_{n-1}$  časovni interval med  $n-1$ -tim in  $n$ -tim vrhom amplitude.

*Varianca hitrosti* je

$$F_{spd-var} = \frac{\sum_{n=1}^{N-1} (V_n - F_{spd-mean})^2}{N-1}.$$

S pomočjo zgornjih definicij so bile pogosto izračunane povprečna, maksimalna in minimalna hitrost odpiranja in zapiranja ter amplituda odpiranja in zapiranja, standardni odklon amplitude odpiranja in zapiranja, povprečje in koeficient variacije amplitude gibanja, hitrosti gibanja (amplituda gibanja/trajanje gibanja), hitrosti gibanja pri odpiranju in zapiranju, hitrost gibanja (število pritiskov glede na čas) in upad amplitude (povprečna amplituda v prvi polovici poskusa v primerjavi s povprečno amplitudo v drugi polovici poskusa) ter prelomna točka amplitude (*breakpoint*,  $F_{amp-bp}$ ) in hitrosti (*breakpoint*,  $F_{vel-bp}$ ).



Slika 4: Shematična označitev odvisnosti amplitude gibanj(A) od števila sličic(t).

## 4.2 Utrujenost oz. zastoj in oklevanje(*halt and hesitation*)

Utrujenost oz. zastoj in oklevanje sta lastnosti pri kateri imamo več različnih pristopov, uporabljenih za njeno oceno.

Zastoj je bil ponavadi opredeljen kot trenutek popolne ustavitve, oklevanje pa kot opazen upad hitrosti. Ta dva pojma so opredelili s pomočjo vrhov  $p = [p_1, p_2, \dots, p_n, \dots, p_N]$ , kjer so uporabili model prilagajanja krivulje množici  $p$ , z namenom ocene trenda vrhov. Predpostavljamo, da je  $p_n$  vrh, ko je prišlo do zastoja in oklevanja,  $\hat{p}_n$  pa predstavlja napovedani vrh na podlagi prilagojenega modela. Potem je značilka zastoja in oklevanja lahko definirana([9]) kot

$$F_{hh} = \begin{cases} 1, & \text{če } |\hat{p}_n - p_n| \geq \theta \\ 0, & \text{če } |\hat{p}_n - p_n| < \theta \end{cases},$$

kjer je prag(*threshold*) definiran kot  $\theta = \alpha \cdot \frac{A_{n+1} + A_{n-1}}{2}$ ,  $\alpha$  pa je parameter, ki nadzoruje zaznamo prag(*detection threshold*).

Utrujenost pa so ponavadi definirali kot

- gradient amplitude glede na čas,
- razlika med številom vrhov v dveh časovnih intervalih,
- koeficient variacije v hitrosti tapkanja,
- razlika med povprečno vrednostjo amplitude v dveh časovnih intervalih,
- koeficient variacije v maksimalni amplitudi tapkanja prstov,
- pospešek tapkanja.

## 4.3 Frekvenca(*frequency*) oz. ritem(*rhythm*)

Uporabljata se oba pojma, ampak ne pomenita vedno isto. Izračun lahko temelji na uporabi hitre Fourierove transformacije(*Fast Fourier Transform*), eden izmed pristopov je tudi uporaba lastnosti “prekrižna korelacija med normaliziranimi vrhovi”(cross-correlation between the normalized peaks) za oceno doslednosti in ritma pri tapkanju.

**Definicija:** Frekvenca je enota, deljena s časovnim razponom enega gibanja. Izračunamo jo po formuli

$$F_{freq} = \frac{1}{tp_n - tp_{n-1}}.$$

Računali pa so predvsem povprečne frekvenca( $F_{freq-avg}$ ) in standardni odklon frekvenca( $F_{freq-sd}$ ).

#### 4.4 Druge značilke

Glede na vrhove  $p = [p_1, p_2, \dots, p_N]$  so računali še število gibanj, štetih po maksimalnih vrhovih, maksimalen vrh( $\max_{i=1, \dots, N} \{p_i\}$ ) in dno( $\max_{i=1, \dots, N} \{m_i\}$ ) ter minimalen vrh( $\min_{i=1, \dots, N} \{p_i\}$ ) in dno( $\min_{i=1, \dots, N} \{m_i\}$ ) amplitude, povprečno število maksimalnih in minimalnih vrhov ter dna glede na določen časovni interval  $t$  ter število vrhov v določenem časovnem intervalu  $t(F_p(t))$ .

Nekateri so v model vključili tudi dva demografska dejavnika - *spol* in *starost*. To temelji na opažanju, da naj bi lahko starejši posamezniki kazali znake bradikinezije, povezane s staranjem, neodvisno od Parkinsonove bolezni, ter da lahko starost in spol vplivata na razvoj bolezni.

#### 4.5 Izbira značilk

Izračunane značilke so ponavadi standardizirali z uporabo metode *StandardScalar*, kar naj bi zagotvaljalo, da vse značilke enako prispevajo k modelu in da ne bi katera izmed značilk prevladovala pri učenju modela ali pa so bile značilke normalizirane s standardno normalno porazdelitvijo(povprečje 0 in standardni odklon 1).

V študijah, kjer so imeli več značilk, so iskali tudi optimalno množico značilk - značilke, ki so najpomembnejše pri klasifikaciji Parkinsonove bolezni. Iskanje optimalne množice značilk se je razlikovalo glede na glavo nalogo zo. cilj študije. Tisti, ki so imeli, poleg nabora podatkov oseb s Parkinsonovo boleznijo, še nabor podatkov zdravih(kontrolnih) oseb, so primerjali značilke, izračunane za obe skupini oseb. Značilke so bile pregledane s pomočjo statističnega testiranja, da se ocenijo porazdelitve v teh dveh skupinah oseb. Ker so značilke pokazale nenormalno porazdelitev s pomočjo Shapiro-Wilkovega testa, so lahko uporabljali Mann-Whitneyev U-test za neodvisne vzorce, za prepoznavanje značilk, ki so v obeh skupinah oseb porazdeljene različno. Uporabljali so značilke, ki so bile, glede na skupino oseb, porazdeljene različno.

Za izbor množice optimalnih značilk so bili uporabljeni tudi različni algoritmi.

Pri algoritmu *Speeded Up Robust Features*(SURF) so bile izbrane značilke s pozitivnim rezultatom, ker to pomeni, da je značilka stabilna, točna in potencialno uporabna za nadaljnje operacije.

Algritem *Reursive Feature Elimination*(RFE) iterativno odstranjuje najmanj pomembne značilke na podlagi uspešnosti modela podpornih vektorjev(SVM), na koncu pa izbere množico, ki najbolje prispeva k nalogi klasifikacije([3]).

*SelectKBest* razvršča značilke glede na njihov *k-score*, metriko, ki meri relevantnost in informativnost posamezne značilke glede na ciljno spremenljivko. Značilke, ki imajo najvišje *k-score*, so prednostno vključene v končni nabor značilk, medtem ko so manj informativne značilke izključene.

Nekateri avtorji so po gradnji modelov na množici izbranih značilk ugotovili, da izključitev določenih značilk in s tem poslabšanje ravnovesja med značilkami povzroči poslabšanje modela, zato so se vselej odločili za gradnjo modela na celotnem naboru značilk.

## 5 Modeli


Osredotočili smo se na pregled del, kjer so izvajali klasifikacijsko napoved, binarno ali multiklasifikacijsko. Glavni cilj študij je torej bil implementirati model za napovedovanje ocen Parkinsonove bolezni po letstviči MDS-UPDRS. Avtorji so za gradnjo in vrednotenje modelov uporabljali knjižnico *scikit-learn* za programski jezik Python, ki ponuja orodja za različne naloge strojnega učenja.

## 5.1 Gradnja modelov

Večina je usposobilo en sam večrazredni klasifikacijski model, kar pomeni, da izhod modela predstavlja vse ocene po lestvici MDS-UPDRS. Nekateri pa so usposobili več binarnih klasifikatorjev. Nekateri delujejo na način, da prvi model razvršča podatke videoposnetkov z oceno 0 v primerjavi z ocenami 1,2 in 3; drugi model razvršča podatke videoposnetkov z ocenama 0 ali 1 v primerjavi z ocenami 2 ali 3; in tretji model razvršča podatke videoposnetkov z ocenami 0, 1 ali 2 v primerjavi z oceno 3. Uporabljen je bil tudi pristop, kjer je prvi model razvrščal zdrave(kontrolne) osebe od oseb s Parkinsonovo boleznijo in če je ta prvi model pokazal, da podatki videoposnetka pripadajo osebi s Parkinsonovo boleznijo, je drugi model razvrstil ocene 1 proti ocenam 2 ali 3. In če je drugi model pokazal, oceno, višjo od 1, tretji model razvrsti ocene 2 proti ocenam 3.

Gradili so različne modele, med najbolj pogostimi pa so bili metoda podpornih vektorjev(SVM, *Support Vector Machine*) z različnimi jedri(*kernels*), ansambli, kot sto naključni gozdovi(RF, *Random Forest*) in XBoost ter običajni klasifikatorji, kot so odločitvena drevesa(*Decision Tree*), model  $k$ -najbližjih sosedov(*k-nearest neighbors*) in logistična regresija(*logistic regression*). V zadnjih letih pa se uporabljajo tudi globoke nevronske mreže(*deep neural networks*).

Zaradi razlik v postopkih, podatkovnih zbirkah, nalogah klasifikacije in uporabljenih klasifikatorjih, ne moremo podati vpogleda, kateri način modeliranja je najboljši za klasifikacijo tapkanja s prsti po lestvici MDS-UPDRS, so pa nekateri avtorji v prvi fazi raziskovanja zgradili več modelov in potem, glede na rezultate, podrobno obravnavali le glavna dva ali tri.



Slika 5: Deleži uporabljenih modelov v preučevanih delih za sledenje rok in zaznavanje drže roke iz videoposnetkov. Oznake: logistična regresija(LR), kNN(k-najbližjih sosedov), odločitvena drevesa(DT), konvolucijske nevronske mreže(CNN), metoda podpornih vektorjev(SVM), naključni gozdovi(RF).

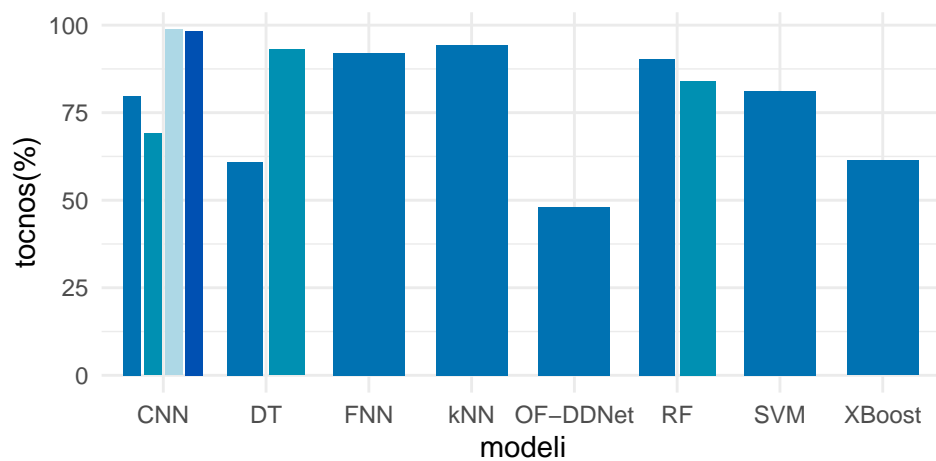
Pri izbiri hiperparametrov modelov so se posluževali različnih algoritmov, kot sta RandomizeSearchCV in GridSearchCV. Pri iskanju so uporabljali le podatke za učenje, da bi dodatno zagotovili robustnost naučenih klasifikatorjev oz. modelov. Podatki so torej bili razdeljeni na učne in testne, ponavadi v razmerju 70%/30% ali 80%/20%, modeli pa usposobljeni z uporabo  $k$ -kratne navzkrižne validacije( $k$  - *Cross Validation*), v večini primerov  $k = 5$ , nekje celo  $k = 10$ , pri čemer so uporabljeni le podatki iz učne množice podatkov.

## 5.2 Vrednotenje modelov

Za vrednotenje modelov so standardno uporabljali štiri različne metrike, točnost(*accuracy*), natančnost(*precision*), priklic(*recall*) in F1, ki temeljijo tabela napačnih klasifikacij (*confusion matrix*). Pogosto je bila primerjava modelov narejena tudi na podlagi ploščine pod krivuljo(AUC, *Area Under Curve*).

## 5.3 Rezultati

V spodnjih tabelah so prikazane študije, njihovi avtorji, ter glavne značilnosti študije([13], [10], [9], [11], [17], [5], [1], [12], [19], [15], [6], [4], [16], [18]) - uporabljeni podatki, cilj študije, preučevan dejavnik Parkinsonove bolezni in uporabljeni modeli strojnega učenja. Pri vsaki študiji, je prvi napisan model v stolpcu "Modeli", model, ki je dosegel najvišjo točnost in bil predstavljen kot končni relevantni model. Na spodnjem grafu lahko še vidimo točnost najboljših modelov v študijah iz tabele.



Slika 6: Točnost modelov v preučevanih študijah.



Tabela 1: Pregledane študije. Oznake: zdrave(kontrolne) osebe(ZO), osebe s Parkinsonovo boleznijo(PB), večrazredna klasifikacija(VK), binarna klasifikacija(BK), tapkanje s prsti(FT), pronacija - spinacija(PS), odpiranje in zapiranje dlani(D), tapkanje s prsti na nogi(TT), mobilnost noge(MN), logistična regresija(LR), k-najbližjih sosedov(kNN), odločitvena drevesa(DT), konvolucijske nevronske mreže(CNN), metoda podpornih vektorjev(SVM), naključni gozdovi(RF).

Avtorji	Leto	Podatki	Cilj študije	Preučevani dejavniki/i PB	Orodje	Modeli
A. Moshkova in drugi	2020	32 videoposnetkov (16 ZO, 16 PB)	Binarna klasifikacija(ima PB ali nima)	FT, PS, D	LM sensor, Microsoft Kinect sensor, Polhemus Patriot Electromagnetic tracking sensors	RF, SVM, DT, kNN
H. Li in drugi	2021	744 videoposnetkov	Ocene po MDS-UPDRS, VK	FT	OpenPose	CNN
M. Lu in drugi	2021	68 Videoposnetkov	Ocene po MDS-UPDRS, VK	FT	OpenPose	OF - DDNet
Z. Li in drugi	2022	252 videoposnetkov	Ocene po MDS-UPDRS, VK	FT	MediaPipe, FCN	CNN
G. Vignouda in drugi	2022	272 videoposnetkov	Ocene po MDS - UPDRS, VK	FT, MH	DeepLabCut	DT, LR
Z. Guo in drugi	2022	112 videoposnetkov (11 ZO, 48 PB)	Ocene po MDS-UPDRS, VK	FT	A2J	SVM, kNN, RF, XGBoost
G. Amprimo in drugi	2023	95 videoposnetkov (60 ZO, 35 PB)	Ocene po MDS-UPDRS, VK, razlikovanje značilk (OZ-PB)	FT	Azure Kinect, MediaPipe	kNN, SVM, RF, XGBoost
G. Morinan in drugi	2023	1156 videoposnetkov (528 ZO, 628 PB)	Ocene po MDS-UPDRS, VK, več BK za ocene MDS-UPDRS	FT, PS, D, TT, MN		RF
T. Yu in drugi	2023	75 videoposnetkov (10 ZO, 65 PB)	Ocene po MDS-UPDRS, VK	FT	MediaPipe	DT, SVM, RF
G. Sarapata in drugi	2023	7310 videoposnetkov	Ocene po MDS-UPDRS, VK	FT, PS, D, TT, MN, vstajanje s stola	OpenPose	CNN, RF, GCN
M. S. Islam in drugi	2023	250 videoposnetkov (78 ZO, 172 PB)	Ocene po MDS-UPDRS, VK	FT	MediaPipe	XBoost, RF, AdaBoost, SVR, LightGBM

Tabela 2: (Nadaljevanje prejšnje tabele.) Pregledane študije. Oznake: zdrave(kontrolne) osebe(ZO), osebe s Parkinsonovo boleznijo(PB), večrazredna klasifikacija(VK), binarna klasifikacija(BK), tapkanje s prsti(FT), pronacija - spinacija(PS), odpiranje in zapiranje dlani(D), tapkanje s prsti na nogi(TT), mobilnost noge(MN), logistična regresija(LR), k-najbližjih sosedov(kNN), odločitvena drevesa(DT), konvolucijske nevronske mreže(CNN), metoda podpornih vektorjev(SVM), naključni gozdovi(RF).

	Avtorji	Leto	Podatki	Cilj študije	Preučevani dejavnik/i PB	Orodje	Modeli
12	D. L. Guarín in drugi	2024	180 videoposnetkov (44 ZO, 123 PB)	Ocene po MDS-UPDRS, VK, več BK za ocene MDS-UPDRS, razlikovanje značilk (OZ-PB)	FT	MediaPipe	LR
13	S. Srinivasan in drugi	2024	195 glasovnih posnetkov (48 ZO, 147 PB)	Binarna klasifikacija(ima PB ali nima)	značilnosti glasu		FNN, kNN, SVM, RF, DT
14	J. Yanga in drugi	2024	152 videoposnetkov (37 ZO, 40 PB)	Binarna klasifikacija(ima PB ali nima), razlikovanje značilk (OZ-PB)	FT	videoposnetki(1s izrezki)	CNN

## Literatura

- [1] G. Amprimo in sod. “Objective Assessment of the Finger Tapping Task in Parkinson’s Disease and Control Subjects using Azure Kinect and Machine Learning”. V: *IEEE 36th International Symposium on Computer-Based Medical Systems* (2023), str. 640–645.
- [2] G. Amprimoa in sod. “Deep Learning for hand tracking in Parkinson’s Disease video-based assessment: Current and future perspectives”. V: *Artificial Intelligence In Medicine* 154 (2024).
- [3] A. Govindua in S. Palwe. “Early detection of Parkinson’s disease using machine learning”. V: *Procedia Computer Science* 218 (2023), str. 249–261.
- [4] D. L. Guarín in sod. “Characterizing Disease Progression in Parkinson’s Disease from Videos of the Finger Tapping Test”. V: *IEEE transactions on neural systems and rehabilitation engineering* 32 (2024), str. 2293–2301.
- [5] Z. Guo in sod. “Vision-Based Finger Tapping Test in Patients With Parkinson’s Disease via Spatial-Temporal 3D Hand Pose Estimation”. V: *IEEE Journal of biomedical and health informatics* 26.8 (2022), str. 3848–3859.
- [6] M. S. Islam in sod. “Using AI to measure Parkinson’s disease severity at home”. V: *NPJ Parkinson’s disease* 156.6 (2023).
- [7] Amo-Salas J. in sod. “A Method for Automatic and Objective Scoring of Bradykinesia Using Orientation Sensors and Classification Algorithms”. V: *Healthcare* 12.439 (2024).
- [8] H. Jeon in sod. “Automatic Classification of Tremor Severity in Parkinson’s Disease Using a Wearable Device”. V: *Sensors* 9.17 (2017).
- [9] H. Li in sod. “Automated assessment of Parkinsonian finger-tapping tests through a vision-based fine-grained classification model”. V: *Neurocomputing* 441 (2021), str. 260–271.
- [10] Z. Li in sod. “An Automatic Evaluation Method for Parkinson’s Dyskinesia Using Finger Tapping Video for Small Samples”. V: *Journal of Medical and Biological Engineering* 42 (2022), str. 351–363.
- [11] M. Lu in sod. “Quantifying Parkinson’s disease motor severity under uncertainty using MDS-UPDRS videos”. V: *Medical Image Analysis* 73 (2021).
- [12] G. Morinan in sod. “Computer vision quantification of whole-body Parkinsonian bradykinesia using a large multi-site population”. V: *NPJ Parkinson’s disease* 1.9 (2023).
- [13] A. Moshkova in sod. “Parkinson’s Disease Detection by Using Machine Learning Algorithms and Hand Movement Signal from LeapMotion Sensor”. V: (2024), str. 321–327.
- [14] Martinez-Manzanera O. in sod. “Computer Vision for Parkinson’s Disease Evaluation: A Survey on Finger Tapping”. V: *IEEE transactions on bio-medical engineering* 5.63 (2016), str. 1016–1024.
- [15] G. Sarapata in sod. “Video-Based Activity Recognition for Automated Motor Assessment of Parkinson’s Disease”. V: *IEEE Journal of biomedical and health informatics* 27.10 (2023), str. 5032–5041.
- [16] S. Srinivasan in sod. “Detection of Parkinson disease using multiclass machine learning approach”. V: *Scientific Reports* 14.13813 (2024).
- [17] G. Vignouda in sod. “Video-Based Automated Assessment of Movement Parameters Consistent with MDS-UPDRS III in Parkinson’s Disease”. V: *Journal of Parkinson’s Disease* 2211–2222.12 (2022).
- [18] J. Yang in sod. “Deep learning of Parkinson’s movement from video, without human-defined measures”. V: *Journal of the Neurological Sciences* 4463 (2024).
- [19] T. Yu in sod. “Clinically Informed Automated Assessment of Finger Tapping Videos in Parkinson’s Disease”. V: *Sensors* 9149.23 (2023).